

다변량 센서 데이터를 활용한 항공기 엔진 수명 예측

RUL 예측 및 비용 최적 유지보수 의사결정

NAME

김새한

E-MAIL

togks7@naver.com

DATE

2026년 3월

DATA SOURCE

NASA Turbofan Engine Degradation Simulation Data Set (FD001)

CONTENTS

01 연구 배경 및 주제선정

02 데이터 소개

03 EDA (탐색적 데이터 분석)

04 Feature Engineering

05 RUL Prediction

06 Failure Probability

07 Decision Policy

08 Conclusion

연구 배경 및 주제 선정

항공기 엔진 예지보전의 필요성
과
데이터 기반 접근 방법



■ 연구 배경

✈ 항공기 엔진과 같은 장비 고장 시 임무 수행 능력이 저하되어 운용정지비용이 발생하며 사후 정비비용이 크다 .

✈ 항공·방산 분야에서 데이터를 활용하여 장비 상태를 분석하고 고장을 예측하는 **예지정비(Predictive Maintenance)**기술과 **잔여수명(RUL)**예측은 장비 가동률 향상과 안정적 장비운영을 위한 핵심 기술이다.

#고비용_정비

#다운타임_최소화

#운영_안전성



■ 주제 선정

머신러닝 기반 **잔여수명 예측 모델**을 구축하고, 데이터 기반 예지정비 방안을 수립해 효율적 유지보수 전략을 분석한다.

🎯 정확한 잔여수명예측을 통해 **최적의 정비 시점**을 결정하는 의사결정 체계를 수립한다.

#머신러닝_모델링

#데이터_기반_의사결정

#비용_최적화

데이터 소개

NASA CMAPSS FD001 데이터셋 및
핵심 변수 정의

NASA CMAPSS FD001 데이터셋 개요 및 분석 절차

데이터셋 구성

항목	내용
엔진 개수	100개
운영 설정	3개 (setting 1~ 3)
센서 개수	21개 (sensor1~ 21)
총 데이터 포인트	23,010개

타겟 레이블 (Target Label)

각 엔진의 고장 직전까지의 주기(cycle)로부터 계산한 **RUL**

데이터 출처: NASA Turbofan Engine Degradation Simulation Data Set

전처리 및 피처 엔지니어링 개요

RUL 계산 각 엔진별 최대 사이클에서 현재 사이클을 뺀 값 (Label Generation)

이동평균 (MA) 센서 노이즈 제거 및 추세 포착 (window=5)

롤링 표준편차 센서 변동성 측정으로 이상 패턴 감지

Lag 피처 이전 시점 데이터로 시간적 의존성 반영

Difference 피처 센서 변화율 계산으로 급격한 열화 포착

02. 데이터 소개 - 주요 변수 및 개념정의



센서 데이터 (Sensor Data)

엔진 건강 상태의 간접 신호

21개 센서 (sensor1~21)를 통해 엔진의 물리적 상태를 실시간 모니터링

주요 측정 항목:

온도, 회전속도, 냉각 시스템 상태, 압력 등



고장 모드 (Failure Mode)

단일 고장 모드 시뮬레이션

High Pressure Compressor (HPC)
성능 저하가 단일고장 원인으로 설정됨

핵심 모니터링 센서:

- **T30** : HPC 출구 온도
- **P30** : HPC 출구 압력
- **Nc** : 코어 회전 속도



RUL (Remaining Useful Life)

타겟 변수 - 잔여 수명


현재 시점부터 엔진이 고장(Failure)까지 남은 **운용 사이클(Cycle)** 수

$$RUL = \text{max cycle} - \text{current cycle}$$

03 EDA

탐색적 데이터 분석을 통한 센서 패턴
및
RUL 관계 파악

엔진 수명 분포 (Max Cycle)



▲ NASA FD001 엔진별 최대 수명 분포



평균 수명 (Mean Life)

전체 100개 엔진의 평균 수명은 **206.3**, 중앙값은 **199.0** cycles



수명 범위 (Life Range)



엔진 수명은 최소 **128 cycles**에서 최대 **362 cycles**까지 넓게 분포
조기 고장과 장기 수명 엔진이 혼재



분산 특성 (Standard Deviation)

표준편차는 **46.34**로, 다양한 고장 시점을 포함한 데이터의 특성 반영

RUL 분포



분포 특성


- 초기 수명 구간보다 중·후반구간에서 빈도가 감소하며 고장 시점에 가까워질수록 데이터 수가 줄어든다
- 극단적 이상치 없이 비교적 안정적인 범위를 보였다.



임계치 기반 정책 민감도 조정

- 데이터셋이 엔진 초기 상태부터 고장 직전까지 다양한 수명 구간을 포함하고 있음을 의미한다.
- 머신러닝 모델이 다양한 열화 상태를 학습할 수 있다.

센서 패턴 ① 명확한 열화 추세 (Monotonic Trend)



▲ sensor2와 sensor7의 명확한 열화 패턴 (엔진 10, 30, 50, 70, 100)



특징: 일관된 증감 패턴

Cycle 증가에 따라 센서 값이 일관되게 증가하거나 감소하는 단조 추세



의미: 고장과의 직접적 상관관계

엔진 열화 상태를 가장 잘 반영하며, RUL 예측 모델의 **핵심 피처**로 작용



시각적 패턴 관찰 (실제 데이터)

그래프에서 **sensor2(증가)**와 **sensor7(증가)**이 시간 경과에 따라 뚜렷한 추세를 보임



해당 센서 목록 (12개)

sensor2

sensor3

sensor4

sensor7

sensor8

sensor11

sensor12

sensor13


sensor15

sensor17

sensor21

sensor20

| 센서 패턴 ② 무변화 센서 (Constant / No Variation)



▲ sensor1 등 완전한 무변화(Constant) 특성을 보이는 센서 패턴

— 특징 (Characteristics)

엔진의 운용 주기에 따라 값이 전혀 변하지 않고 일정하게 유지되는 패턴을 보임


☞ 의미 및 영향

정보량이 전혀 없어 모델링에 도움이 되지 않으며, 노이즈로 작용할 가능성이 존재해 **제거 대상(Drop)**으로 분류

☰ 해당 센서 목록 (6개) REMOVE

- sensor1
- sensor5
- sensor10
- sensor16
- sensor18
- sensor19

| 센서 패턴 ③ 불규칙 변화 센서 (Non-monotonic / Irregular Trend)



▲ sensor6와 sensor9의 불규칙한 열화 패턴 (엔진 10, 30, 50, 70, 100)

**불규칙한 변동성 (Irregularity)**

Cycle의 진행에 따라 값이 일관되게 변화하지 않고
증가와 감소가 불규칙하게 나타남

**예측 제한 및 보조 활용**

직접적인 RUL 예측 모델의 변수로 사용하기에는 제한적이나,
다른 센서와의 결합을 통해 보조 지표로 활용 가능성 존재

**통계적 특성 추출 필요**

원데이터보다는 이동평균, 표준편차 등의 통계적 변환을 거쳐
유의미한 특성을 추출 가능


**해당 센서 목록 (3개)**

sensor6

sensor9

sensor14

RUL – Sensor 상관관계



핵심 상관관계 센서 식별

상관계수 0.5 이상의 강한 선형 관계를 가지는 주요 변수들

강한 양의(+) : sensor7, 12, 20, 21

강한 음의(-) : sensor2, 3, 4, 8, 11, 13, 15, 17



Feature Selection 제거 기준

상관계수가 0에 수렴하는 변수들

제거 대상 : 상관관계 0


해당 센서 : sensor1, 5, 10, 16, 18, 19

04 Feature Engineering

시계열 특성 추출 및 파생 변수 생성

04. Feature Engineering

이동평균/표준편차



▲ 이동평균(MA) 및 롤링 표준편차(STD) 분석 그래프



이동평균 (Moving Average)


센서 데이터의 불규칙한 노이즈를 스무딩(Smoothing)하여 **장기적인 열화 추세**를 명확하게 표현. 엔진 상태의 전반적인 변화 패턴을 파악하는 데 도움을 주는 요소



표준편차 (Rolling Std Dev)

일정 윈도우(5) 내 데이터의 **변동성(Volatility)**을 측정하여 고장 시점에 가까워질수록 증가하는 신호의 흔들림을 포착

Lag/Difference



▲ 시계열 데이터의 이력(Lag) 및 변화량(Difference) 피쳐 시각화

이력(Lag) 및 변화량(Diff) 반영

Lag 피쳐를 통해 과거 시점의 상태 정보를 반영
Difference 피쳐로 데이터의 변화량(기울기) 정보를 통해
시계열적 특성 반영

급격한 상태 변화 조기 감지

센서 데이터의 단순 수치뿐만 아니라 변화의 속도와 방향을 학습
해 고장 전조 증상인 단기적인 급격한 변화를 조기에 감지하여
위험도 판단에 기여

Result

Model	Feature Set	RMSE	MAE	R ²
Random Forest	Baseline	15.978	10.849	0.853
	Rolling Mean + Rolling Std	15.155	10.054	0.868
	Lag + Diff	15.326	10.503	0.865
	All Features ★	15.088	10.040	0.869
XGBoost	Baseline	16.084	10.909	0.851
	Rolling Mean + Rolling Std	15.496	10.308	0.862
	Lag + Diff	15.349	10.445	0.865
	All Features ★	15.333	10.326	0.865



Feature Engineering 결과 4가지 파생변수를 결합 한 경우에 Random Forest, XGBoost 두 모델에서

baseline 대비 RMSE, MAE, R² 점수가 개선되며 가장 우수한 성능을 보였다.

Drop Features

제거 센서 목록 (7개) REMOVE

- sensor1
- sensor5
- sensor6
- sensor10
- sensor16
- sensor18
- sensor19

Feature Selection 제거 기준



상관관계
RUL과 Sensor의 상관관계

RUL과의 상관관계가 매우 낮은 센서는 예측에 유의미한 정보를 제공하지 않을 가능성이 있음

RUL과의 상관계수 ≈ 0
sensor1, sensor5, sensor10
sensor16, sensor18, sensor19



열화패턴 그래프
Cycle에 따른 Sensor의

Cycle 증가에 따라 열화 패턴을 보이지 않는 센서는 RUL 예측에 활용도가 낮음

무변화 센서:
sensor1, sensor5, sensor10,
sensor16, sensor18, sensor19

불규칙 변동 센서:
Sensor6, sensor9, sensor14




Feature importance
Baseline 모델 기반 중요도

Feature Importance 결과 (하위 센서)

sensor17	0.003691	sensor10	0.000000
sensor6	0.000106	sensor16	0.000000
sensor5	0.000000	sensor19	0.000000
sensor1	0.000000	sensor18	0.000000

Final Selected Features



05 RUL Prediction

Random Forest 모델을 활용한 잔여 수명 예측

05. RUL Prediction

Model Selection

Model	Setting	RMSE	MAE	R ²
Random Forest	Baseline	15.978	10.849	0.853
	★ Tuned	14.406	10.117	0.881
XGBoost	Baseline	16.084	10.909	0.851
	Tuned	14.782	10.248	0.874

최종 선정 모델: Random Forest



- 모든 평가 지표(RMSE, MAE, R²)에서 가장 우수한 성능을 보임
- 복잡한 비선형 패턴과 다양한 변수 간 상호작용을 효과적으로 학습하여 데이터 구조를 안정적으로 반영하는 예측력을 확보함
- 이상치나 노이즈가 포함된 산업 장비 데이터에서도 **강건한 성능**을 유지하는 특성이 있어 실제 운영 환경에 적합함.

모델링 전략



Validation Strategy : GroupKFold Cross Validation
동일 엔진의 데이터가 train/validation에 분할되어 들어가지 않도록 **Engine_id** 기준 그룹 분할

Optimization : RandomizedSearchCV
넓은 매개변수 공간을 효율적으로 탐색하여 최적 파라미터 도출

05. RUL Prediction

Model Selection

Random Forest Regressor

Test R^2 Score

0.823

High Accuracy (설명력 81.5%)

Test RMSE

16.83

Cycles (평균 제곱근 오차)

Test MAE

11.20



Cycles (평균 절대 오차)

★ Top 3 Features

1. sensor4_ma

2. sensor11_ma

3. sensor15_ma



분석 결과: 랜덤 포레스트 모델은 테스트 데이터셋에 대해 높은 설명력(R^2)을 보이며, 실제 RUL과 예측 RUL이 대각선($y=x$)을 중심으로 잘 분포함. 특히 수명 말기(RUL < 50) 구간에서의 예측 정확도가 중요하며, 오차 분포가 안정적임을 확인

05. RUL Prediction

Sharp (Feature Importance)



Top 5 Features

1. cycle

2. sensor4_MA

3. sensor11_MA

4. sensor15_MA

5. sensor12_MA



주요 변수 영향 분석


- 엔진운용시간은 RUL 예측에 직접적인 영향을 줌
- 이동평균(ma5)이 주로 핵심 변수에 포함됨
- sensor4, 11, 15가 엔진 수명판단의 핵심 지표로 활용됨



이동평균 (Moving Average)

- 단기 노이즈를 완화하고 장기적인 변화추세를 반영
- 열화는 점진적으로 진행되므로 추세 기반 요인이 효과적

SHAP Feature Importance



06. Failure Probability

RUL 기반 고장 확률 분석 및 리스크 평가

RUL – Failure Probability

🔄 Sigmoid 기반 고장확률 산출

잔존 수명(RUL)을 0과 1 사이의 고장 확률로 매핑



Sigmoid 함수로 수명 말기에 성능 저하가 급격히 발생하는 비선형적 특성을 반영

$$FP = 1 / (1 + e^{\frac{RUL - C}{scale}})$$

📊 확률 분포 특징

고장 시점이 다가올수록 확률이 지수적으로 증가

정상상태와 위험상태를 구분하는 지표로 활용



06. Failure Probability

RUL – Failure Probability

C: 평균 수명의 하위 30% 시점

P: 고장확률

✓ Low Risk

정상 운용 상태 (Normal)
특이사항 없음. 정기적인 모니터링 수행

$RUL > C$ or $P < 30\%$

⚠ Medium Risk

주의 관찰 단계 (Warning)
성능 저하 징후 포착. 예방 정비 계획 수립



$RUL \leq C$ or $P \geq 30\%$

☢ High Risk

긴급 정비 필요 (Critical)
고장 임박. 즉각적 운영 중단 및 정비 시행

$RUL \leq C * 0.5$ or $P \geq 70\%$

엔진별 고장 확률 추이 (Failure Probability Trend)



임계값(Threshold) 설정 근거

- 현장 운영자가 직관적으로 이해할 수 있는 경보 시스템설계에 활용
- 0.3과 0.7은 오경보를 줄이고 정비 골든타임을 확보하는 임계치

핵심 메시지



예측된 RUL을 고장 확률로 변환하고, RUL과 FP를 통해 엔진 상태를 실시간으로 진단합니다. 이를 통해 선제적인 예방 정비가 가능해집니다.

07

07. Decision Policy

RUL 및 고장 확률 기반
유지보수 의사결정 체
계

05. RUL Prediction

Cost based Maintenance

정비 비용 가정

예방 정비	200 만원	계획 정비, 부품 교체 기준
사후 정비	2000만원	긴급 수리, 운용 중단 손실 포함
비용비율	1:10	항공 엔진 정비 일반 기준 적용

비용 절감률




79.2%

예지보전 총비용

14,813.1


반응형 총비용

71,299.2



정책 구조 및 의사결정

의사결정 흐름도



정책별 조치

Immediate

- 즉각 운용 중단
- 긴급 정비 투입
- 우선정비 1순위

Plan

- 정비 일정 수립
- 부품 사전 확보
- 모니터링 강화

normal

- 정상운용 유지
- 정기 점검 수행
- 다음 주기 재평가

기준값

C(center) : 엔진 평균수명의 30%시점
C * 0.5 : 긴급임계값

고장확률(P)

예측된 RUL을 sigmoid 함수로 변환해 0~1 사이의 고장 임박 확률로 변환한 값

08

08. Conclusion

연구 성과 요약 및 향후 발전 방향

i 결론 및 기대효과



정량적 성과

Quantitative Achievements

- ✓ RUL 예측 정확도 R^2 0.823 달성
- ✓ 반응형 정비 대비 비용 79.2% 절감 효과
- ✓ 예측 오차(RMSE) 16.83수준으로 안정적



비즈니스 임팩트

Business Impact

- ✓ 데이터 기반의 정비 계획 최적화
- ✓ 부품 재고 및 인력 등 자원 배치 효율화
- ✓ 엔진 돌발 고장 방지 및 다운타임(Downtime) 최소화



향후 고도화 계획

Future Enhancement

- ✓ 실시간 장비 모니터링 대시보드 구축
- ✓ 다양한 알고리즘을 결합한 앙상블 모델
- ✓ 신규 데이터 유입에 따른 주기적 모델 재학습 체계 마련